

无线电工程

Radio Engineering

ISSN 1003-3106, CN 13-1097/TN

《无线电工程》网络首发论文

题目：基于云边协同的任务卸载策略技术研究
作者：朱仪，江雪
网络首发日期：2024-10-10
引用格式：朱仪，江雪．基于云边协同的任务卸载策略技术研究[J/OL]．无线电工程．
<https://link.cnki.net/urlid/13.1097.tn.20241010.0924.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于云边协同的任务卸载策略技术研究

朱仪^{1,2}, 江雪^{1,2}

(1. 南京邮电大学 物联网学院, 江苏 南京 210003;

2. 南京邮电大学江苏省通信与网络技术工程研究中心, 江苏 南京 210003)

摘要：随着 5G 技术的发展，越来越多的移动设备连接到网络中，产生了大量的异构计算任务。为了满足用户需求实现快速响应和实施决策，本文研究了一个基于云边协同的任务卸载策略技术，这些任务会在边缘节点和云服务器进行处理和分析。由于边缘节点和移动设备能耗资源有限，本文采用智能优化算法，动态分配计算资源，结合边缘节点和云服务器的计算能力，以最小化系统总能耗为目标进行研究。仿真实验表明，基于云边协同的任务卸载策略技术显著提高了计算资源的利用率，降低了整体能耗。这证明了基于云边协同的移动边缘计算(Mobile Edge Computing, MEC)网络中动态卸载决策和优化资源分配有效提升了系统的性能和可靠性，支持更快的用户响应和决策实施。

关键词：移动边缘计算；云边协同；能耗；智能优化算法

中图分类号: TN925

文献标志码: A

开放科学(资源服务)标识码(OSID):



Research on Task Offloading Strategy Technology Based on Cloud-edge Collaboration

ZHU Yi^{1,2}, JIANG Xue^{1,2}

(1. School of Internet of Things, Nanjing University of Posts and Telecommunications, Nanjing 210003, China;

2. Jiangsu Engineering Research Center of Communication and Network Technology, Nanjing University of Posts and Telecommunications, Nanjing 210003, China)

Abstract: With the development of 5G technology, more and more mobile devices are connected to the network, resulting in a large number of heterogeneous computing tasks. In order to meet user needs and realize rapid response and implementation decision, this paper studies a task offloading strategy technology based on cloud-edge

基金项目：国家自然科学基金项目(62001248, 61971241); 南京邮电大学江苏省通信与网络技术工程研究中心开放课题资助(JSGCZX23007); 杭州昊舜视讯科技有限公司校企合作项目(2024 外 105)

Foundation Item: National Natural Science Foundation of China (62001248, 61971241); The Open Research Fund of Jiangsu Engineering Research Center of Communication and Network Technology (JSGCZX23007); Hangzhou Haovision Technology Co., Ltd school enterprise cooperation project (2024out105)

collaboration. These tasks will be processed and analyzed at the edge nodes and the cloud server. Due to the limited energy consumption resources of edge nodes and mobile devices, this paper adopts intelligent optimization algorithms to dynamically allocate computing resources, combines the computing power of edge nodes and cloud servers, and studies the total energy consumption of the system as the goal. Simulation results show that the task offloading strategy technology based on cloud-edge collaboration significantly improves the utilization of computing resources and reduces the overall energy consumption. This proves that the dynamic offloading decision and optimal resource allocation in the Mobile Edge Computing (MEC) network based on cloud and edge collaboration effectively improve the performance and reliability of the system, and support faster user response and decision implementation.

Keywords: MEC; Cloud-edge Collaboration; Energy Consumption; Intelligent Optimization Algorithm

0 引言

随着移动通讯技术和智能终端的普及,各种计算密集型应用不断涌现,但由于终端的计算能力和电量有限,难以满足这些应用的需求。为此,MEC作为一种有效方法,通过在靠近用户的边缘端配置强大节点,让用户可以将计算任务转移到更强大的网络边界,以缓解终端资源的限制,降低能耗,提高用户体验。随着应用场景的复杂化和多样化,仅依靠MEC已经难以满足全部需求。云边协同的出现解决了这一问题。云边协同技术通过将计算和数据处理分布在云端和边缘设备之间,有效提升了系统的响应速度和处理效率。它在智能城市和无人驾驶等领域展现出巨大潜力。在智能城市中,云边协同实现了实时交通管理和安防监控,减少数据传输延迟并优化资源利用。无人驾驶中,边缘计算支持车辆实时决策,如避障和路径规划,提升安全性和反应速度。随着技术的发展,云边协同将在更多场景中发挥关键作用,为智能化应用带来更高的效率和可靠性。

近年来,国内外学者对云边协同技术进行了大量研究。文献[1]研究了云边缘协同系统中的资源分配和功耗问题,将问题简化为约束优化问题,降低能耗。文献[2]提出了一个通过云边缘协作机制进行服务质量预测的多中心联邦学习框架,减少时延。文献[3]融合边缘云与远端云构建了一种分层的边缘云计算架构,有效降低移动终端能耗。文献[4]研究了云计算和边缘计算之间的协作,有效降低了移动设备的延迟。文献[5]提出了一种协同计算框架,使移动设备的任务可以在终端、边缘节点和云中心进行部分处理,有效降低了时延。文献[6]提出一种基于深度强化学习的云边协同负载均衡优化算法,以选择最佳的边缘节点或云服务器进行任务卸载,降低任务丢包率、平均时延和终端设备能耗。文献[7]提出一种云边协同区域能源互补决策模型与算法,有效缓解云平台通信和计算压力。在云边协同中,边缘计算与云计算是互补的关系,云计算依赖边缘计算,包括对海量数据的处理、隐私处理,从而满足实时、

能耗和隐私安全等需要；边缘计算也依靠云计算强大计算等能力和海量资源的支持。

为了更高效地找到最优解的解决方案，智能优化算法是一个不错的选择。文献[8]利用遗传算法得到计算和无线资源分配策略，降低了系统的总能耗。文献[9–10]采用遗传算法优化计算成本与能耗进而得到卸载决策。文献[11–12]利用模拟退火算法全局寻优能力求解卸载决策，减少多接入环境和高需求应用的能耗。文献[13]结合灰狼和混合鲸鱼优化算法实现卸载决策目标优化。文献[14]采用人工蜂群算法求解策略后再将各服务器结果进行整体对比选择任务执行节点。文献[15–16]采用粒子群算法得到任务迁移决策和计算资源分配方案。文献[17]应用 PSO 作为卸载决策算法处理计算密集型 and 时延敏感型任务。文献[18]设计了一种基于遗传模拟退火的求解算法，保持了遗传算法较强的全局搜索能力，通过模拟退火降温过程提高了算法的收敛速度。因此，云边协同技术搭配智能优化算法能够更有效的给出任务卸载和资源分配策略，从而降低能耗，减少时延。

随着移动设备的增多，网络中的用户需求量增大，基站的负荷越来越大，为了缓解此类问题，需要考虑用户接入问题，实现负载均衡。文献[19]考虑了缓存无人机网络中的用户传输开销，使用博弈论对无人机部署和缓存空间分配的联合优化问题进行建模。文献[20]研究了缓存无人机辅助地面通信网络中的无人机轨迹、传输功率以及缓存配置的联合优化问题，采用交替迭代的算法最大化被服务用户的最小吞吐量。文献[21]研究了物联网系统中缓存无人机的位置部署与缓存配置的联合优化问题，优化目标为覆盖用户的最大吞吐量。文献[22]研究了空地网络中的无人机位置、用户接入以及缓存配置的联合优化问题。

上述文献[13][14][15–16][17][18]等在处理任务卸载时没有充分考虑实际应用中的复杂情况，只考虑解决任务卸载策略问题，存在着一定局限性，并且文献[14][17]在解决问题时并没有充分利用高效的算法，结果的可靠性和有效性可能受到一定影响。因此本文研究基于云边协同的移动边缘计算网络中能耗最小化资源分配技术，采用智能优化算法有效求解任务卸载和资源分配策略。本文将需求解云边协同的优化问题分为 2 个子问题，一是用户接入问题，二是资源分配和任务卸载策略问题。

1 系统模型

在 MEC 网络中，考虑一个云服务器、 J 个单天线的边缘节点和 I 个移动设备，记为集合 $\mathcal{J} = \{1, 2, \dots, J\}$ 和 $\mathcal{I} = \{1, 2, \dots, I\}$ 。每个边缘节点都连接一个边缘节点，它的数据处理、缓存和储资源都有限，将一个基站和它对应的边缘服务器看做一个边缘节点，每个边缘节点所连接的移动设备分别记为集合 I_1, I_2, \dots, I_J 。假设每个移动设备都在所有边缘节点的服务范围内，

通过智能优化算法计算得出每个边缘节点服务的移动设备的集合记为 $\Psi_1, \Psi_2, \dots, \Psi_J$ 。基于云边协同的 MEC 网络模型如图 1 所示。




图1 基于云边协同的MEC网络模型

Fig. 1 MEC network model based on cloud-edge collaboration

在上述网络模型中，每个移动设备的计算任务既可以部分在边缘节点完成，也可以部分在云服务器完成。假设边缘节点位于地面，高度 $h=0$ ，用 $j \in \mathcal{J}$ ，边缘节点的所在位置坐标为 $G=(Dx_j, Dy_j)$ ；移动设备也位于地面，用 $i \in \mathcal{I}$ ，移动设备 i 的位置为 $v_i=(dx_i, dy_i)$ 。假设所有移动设备中对应的任务类型相同并且同时到达边缘节点，第 j 个边缘节点执行第 i 个移动设备的任务的数据量记为 $L_{j,i}$ 。移动设备 i 与边缘节点 j 间的距离 $d_{j,i}$ 可表示为：

$$d_{j,i} = \sqrt{(Dx_j - dx_i)^2 + (Dy_j - dy_i)^2}。 \quad (1)$$

定义 $\lambda_{j,i} \in [0,1]$ 表示在边缘节点执行的任务所占比例，第 j 个边缘节点将接收到第 i 个移动设备的任务 $L_{j,i}$ 分为两部分，一部分任务 $\lambda_{j,i}L_{j,i}$ 在边缘节点执行，同时将部分任务 $(1-\lambda_{j,i})L_{j,i}$ 交给云服务器处理。云服务器将总的计算资源分配给所有移动设备的计算任务，并执行云计算。计算完成后，将计算结果返回对应的边缘节点。边缘节点收集自己和云服务器的计算结果并回传给每个移动设备。

定义 $p_{j,i}$ 表示第 i 个移动设备到第 j 个边缘节点的发送功率。设移动设备和它连接的边缘节点之间的信道为独立同分布的瑞利信道。当多个设备同时进行数据传输时，移动设备 i

与边缘节点 j 间的信道增益 $h_{j,i}$ 可表示为:

$$|h_{j,i}|^2 = d_{j,i}^{-\alpha} |\zeta|^2, \quad (2)$$

式中: α 表示路径损耗因子, ζ 表示瑞利衰落系数。

第 j 个边缘节点相连的移动设备 i 的 SNR 可以表示为:

$$SNR_{j,i} = \frac{|h_{j,i}|^2 P_{j,i}}{\sigma_i^2}, \quad (3)$$

其中: σ_i^2 表示第 i 个移动设备的噪声功率。

根据香农公式, 每个移动设备的平均可达速率可以表示为:

$$r_{j,i} = a_{j,i} B \log(1 + SNR_{j,i}), \quad (4)$$

式中: $a_{j,i}$ 表示在第 j 个边缘节点接收到第 i 个移动设备任务卸载的带宽分配比例, B 表示信道带宽。

在云边协同的移动边缘计算网络中, 系统总能耗主要包括移动设备能耗、边缘节点能耗和云服务器能耗, 本文主要考虑计算任务在边缘端和云端执行, 所以忽略移动设备的能耗。

(1) 边缘节点能耗

边缘节点的能耗主要由卸载能耗、计算能耗和任务返回能耗三个部分组成:

① 卸载能耗

卸载能耗是指移动设备上的计算任务将部分或全部卸载到边缘节点的能耗。任务 $L_{j,i}$ 由第 i 个移动设备卸载到第 j 个边缘节点的卸载能耗可以由下式计算得到:

$$E_{j,i}^{\text{tran,e}} = \frac{P_{j,i} L_{j,i}}{r_{j,i}}. \quad (5)$$

② 计算能耗

计算能耗是指在移动设备中执行计算任务时所需的能耗。第 j 个边缘节点执行计算任务 $\lambda_{j,i} L_{j,i}$ 需要消耗的计算能耗为:

$$E_{j,i}^{\text{comp,e}} = \rho_e \times f_j^2 \lambda_{j,i} L_{j,i}, \quad (6)$$

式中: $\rho_e \times f_j^2$ 表示 CPU 循环 1 个周期所产生的能耗, ρ_e 表示由芯片结构而定的开关电容。

③ 任务返回能耗

为了简化计算，假设边缘节点计算完成的计算任务的能耗与原任务成一定比例，因此边缘节点 j 将所有计算任务计算完成后得到的结果返回第 i 个移动设备的能耗可以表示为：

$$E_{j,i}^{\text{re,e}} = \gamma_1 E_{j,i}^{\text{tran,e}}, \quad (7)$$

式中： γ_1 为固定系数。

由上面的分析可以看出，通过第 j 个边缘节点完成第 i 个移动设备的计算任务，边缘节点的总能耗可以表示如下：

$$E_{j,i}^{\text{e}} = E_{j,i}^{\text{tran,e}} + E_{j,i}^{\text{comp,e}} + E_{j,i}^{\text{re,e}}。 \quad (8)$$

(2)云服务器能耗

云服务器能耗主要由任务卸载能耗、执行计算任务能耗和任务回传能耗三部分组成：

①传输能耗

传输能耗是指云服务器接收边缘节点的传输任务所需的能耗。云服务器接收边缘节点的传输任务 $(1-\lambda_{j,i})L_{j,i}$ 需消耗能耗为：

$$E_{j,i}^{\text{tran,c}} = p_j^{\text{E}} \frac{(1-\lambda_{j,i})L_{j,i}}{R_j}, \quad (9)$$

式中： R_j 表示第 j 个边缘节点与云服务器之间的传输速率， p_j^{E} 表示第 j 个边缘节点的发送功率。

②计算能耗

计算能耗是指云服务器执行计算任务所需的能耗。云服务器执行计算任务 $(1-\lambda_{j,i})L_{j,i}$ 消耗的能耗可以表示为：

$$E_{j,i}^{\text{comp,e}} = \rho_c \times f_c^2 (1-\lambda_{j,i})L_{j,i}, \quad (10)$$

式中： $\rho_c \times f_c^2$ 表示CPU循环1个周期所产生的能耗， ρ_c 表示由芯片结构确定的开关电容。

③任务回传能耗

为了简化计算，假设云服务器计算完成的计算任务的能耗与原任务成一定比例，因此云服务器将计算结果数据回传给第 j 个边缘节点再返回第 i 个移动设备的能耗可以表示为：

$$E_{j,i}^{\text{re,c}} = \gamma_2 E_{j,i}^{\text{tran,c}}, \quad (11)$$

式中： γ_2 为固定系数。

通过上述分析，可得云服务器的总能耗可以表示如下：

$$E_{j,i}^c = E_{j,i}^{\text{tran},c} + E_{j,i}^{\text{comp},e} + E_{j,i}^{\text{re},c} \circ \quad (12)$$

完成第 j 个边缘节点对应第 i 个设备的计算任务时，需要消耗的总能耗可以表示：

$$E_{j,i} = E_{j,i}^e + E_{j,i}^c \circ \quad (13)$$

2 问题描述以及智能优化算法求解

本章在云边协同边缘计算网络中以能耗最小化为目标，将用户接入问题以及资源分配和任务卸载策略问题建模为非凸的组合优化问题，并通过模拟退火算法^[23](Simulated Annealing Algorithm, SAA)、蚁群算法^[24] (Ant Colony Algorithm ACA)、粒子群算法^[25] (Particle Swarm Optimization, PSO)、遗传算法^[26] (Genetic Algorithm, GA) 4 种智能优化算法求解。

2.1 用户接入问题

由于移动设备能耗有限，他们将计算任务卸载到边缘节点上，从而减轻移动设备上计算任务的负担。在任务卸载中，移动设备到边缘节点的距离会显著影响卸载传输能耗，因此确定移动设备选择哪个边缘节点进行任务卸载至关重要。

定义二进制矩阵 $\mathbf{X} = \{x_{j,i}\}$ 表示边缘节点与移动设备之间的连接关系， $x_{j,i} = 1$ 表示第 i 个移动设备选择第 j 个边缘节点卸载任务， $x_{j,i} = 0$ 表示第 i 个移动设备与第 j 个边缘节点不连。假设系统中每个移动设备只能连接一个边缘节点卸载任务，因此需满足如下条件

$$x_{j,i} \in \{0,1\}, \sum_{j=1}^J x_{j,i} = 1, \forall i \in \mathcal{I}, \forall j \in \mathcal{J} \circ \quad (14)$$

在 MEC 网络中，由于移动设备的能耗远低于边缘节点和云服务器的能耗，因此系统中的总能耗主要考虑边缘节点能耗和云服务器加权能耗之和，系统总能耗表示如下：

$$E_{ai} = E_{j,i}^e + E_{j,i}^c \circ \quad (15)$$

在云边协同边缘计算网络中，用户接入问题的优化问题可以表示为：

$$\begin{aligned} \min_{x_{j,i}} \quad & \sum_{j=1}^J \sum_{i=1}^I E_{j,i}^e + E_{j,i}^c, \\ \text{s.t.} \quad & C1: x_{j,i} \in \{0,1\}, \sum_{j=1}^J x_{j,i} = 1, \forall i \in \mathcal{I}, \forall j \in \mathcal{J} \\ & C2: \sum_{j=1}^J \sum_{i \in \Psi_j} E_{j,i}^e \leq E_j \\ & C3: \Psi_{k_1} \cap \Psi_{k_2} = \emptyset, \forall k_1, k_2 \in \mathcal{J}, k_1 \neq k_2 \end{aligned} \quad (16)$$

$$C4: \Psi_1 \cup \Psi_2 \cdots \cup \Psi_j = \mathcal{I}$$

式中：C1 表示每个移动设备只能选择一个边缘节点卸载任务；C2 表示边缘节点的能量限制；C3 表示任意 2 个边缘节点不会同时接入相同的移动设备；C4 表示所有边缘节点接入的移动设备属于集合 \mathcal{I} 。

(1) SAA 求解用户接入问题

初始化初始温度 T_0 、结束温度 T_{\min} 、温度下降速率 r 。

计算能耗增量 $d=E(n)-E(n-1)$ 。

若 $d<0$ ，则接收 X 更新当前解；否则计算 X 的接受概率 $P=e^{-d/T_n}$ 。其中 T_n 为当前温度。

若 $rand<e^{-d/T_n}$ ，接受 X 作为当前解；否则保留当前解。

温度更新 $T_n = r \times T_{n-1}$ ，容差更新 $\delta = abs(E(n)-E(n-1))$ 。

(2) ACA 求解用户接入问题

计算 m 只蚂蚁的状态转移概率 $P(n,1:m) = \frac{E(n,1:m) - E_{\min}}{E_{\min}}$ 。

m 只蚂蚁分别判断是否移动，若 $P(n,1:m) < P_0$ ，访问未访问过的位置 $q_{new}(1:m)$ ，并计算新位置的能耗 $E(q_{new}(1:m))$ ，

若新位置的能耗对应函数值小于原先位置的能耗数值，则进行移动；否则不动。

更新信息素 $E_{\min} = (1-\rho) \times E_{\min} + E(q_{new}(1:m))$ 。

(3) PSO 求解用户接入问题

初始化群体粒子个数 N_p ，惯性权重 w ，惯性权重最大和最小值分别为 W_{\max} 、 W_{\min} ，速度最大值和最小值 v_{\max} 、 v_{\min} 。

若第 j 个粒子的 $E(j) < y_{best}(j)$ ，更新个体最优位置 $y(:,j) = Y(:,j)$ 和最优值 $y_{best}(j) = E(j)$ ；否则不更新位置。

若 $y_{best}(j) < g_{best}(j)$ ，更新全局最优位置 $g = y(:,j)$ 和最优值 $g_{best} = y_{best}(j)$ ；否则不更新。

计算动态惯性权重值 $w = W_{\max} - (W_{\max} - W_{\min}) \times n / T$ 。

更新粒子移动速度 $v(j,1) = w \times v(j,1) + c \times rand \times (y(:,j) - Y(:,j)) + c \times rand \times (g - Y(:,j))$ 。

(4) GA 求解用户接入问题

初始化 NP 组方案，交叉概率 P_c ，变异概率 P_m 。

求 NP 个基于(16)的能耗的相反数，即每个个体适应度 $E(1:NP)$ 。

选择：采用轮盘赌选择策略，计算出 E 中数值的总和 $sum_E(n)$ 以及每一个个体的概率

$$P(i) = E(i) / sum_E(n)。$$

交叉：随机生成 $P_1 = rand$ ，若 $P_1 < P_c$ ，则 $r_1 = randi([1, I])$ ， $r_2 = randi([1, I])$ ， $Y(r_1:r_2, i)$ 与 $Y(r_1:r_2, i+1)$ 交换。

变异：随机生成 $P_2 = rand$ ，若 $P_2 < P_m$ ，则 $r_3 = randi([1, I])$ ， $Y(r_3, i) = randi([1, I])$ 。

2.2 资源分配和任务卸载策略问题

为了实现能耗最小化，目标是最小化完成所有任务产生能耗的加权和，本文将为所有需计算任务合理地分配计算资源，并且为了满足边缘节点计算总任务的限制条件，建立优化问题可以表示为：

$$\begin{aligned} \min_{p_{j,i}, a_{j,i}, \lambda_{j,i}} \quad & \sum_{j=1}^J \sum_{i=1}^I E_{j,i}^e + E_{j,i}^c \quad (17) \\ \text{s.t. C1: } \quad & \sum_{j=1}^J \sum_{i \in \Psi_j} E_{j,i}^e \leq E_j \\ \text{C2: } \quad & 0 \leq p_{j,i} \leq p_{\max}, \forall i \in \mathcal{I}, \forall j \in \mathcal{J} \\ \text{C3: } \quad & \sum_{j=1}^J \sum_{i=1}^I a_{j,i} \leq 1, 0 \leq a_{j,i} \leq 1, \forall i \in \mathcal{I}, \forall j \in \mathcal{J} \\ \text{C4: } \quad & 0 \leq \lambda_{j,i} \leq 1, \forall i \in \mathcal{I}, \forall j \in \mathcal{J} \end{aligned}$$

其中，C1 表示边缘节点能量的限制；C2 表示第 i 个移动设备到第 j 个边缘节点的发送功率的限制；C3 表示带宽分配比例的约束；C4 表示卸载任务比例的限制。

(1) SAA 求解资源分配和任务卸载策略优化问题

计算能耗增量 $d = E(p(n), a(n), \lambda(n)) - E(p(n-1), a(n-1), \lambda(n-1))$ 。

若 $d < 0$ ，则接收 $(p(n), a(n), \lambda(n))$ 更新当前解；否则计算 $(p(n), a(n), \lambda(n))$ 的接受概率 $p = e^{-d/T_n}$ 。若 $rand < e^{-d/T}$ ，接受 $(p(n), a(n), \lambda(n))$ 作为当前解；否则保留当前解 $(p(n-1), a(n-1), \lambda(n-1))$ 。

温度更新 $T_n = r * T_{n-1}$ 。

(2) ACA 求解资源分配和任务卸载策略优化问题

计算第 m 只蚂蚁的状态转移概率 $P(n, 1:m) = \frac{E(n, 1:m) - E_{\min}}{E_{\min}}$ 。其中 E_{\min} 表示第 n 次迭代

系统总能耗的最小值。 m 只蚂蚁分别判断是否移动, 若 $P < P_0$, 进行局部搜索; 否则进行全局搜索。

若 $E(n) < E(n-1)$, 则移动到新位置 $(p(n), a(n), \lambda(n))$; 否则位置不变。

更新信息素 $E_{\min} = (1 - \rho) * E_{\min} + E(n, 1:m)$ 。

(3) PSO 求解资源分配和任务卸载策略优化问题

若 $E(p(j), a(j), \lambda(j)) < E_{best}(j)$, 更新个体最优位置 $(p_{best}(j), a_{best}(j), \lambda_{best}(j)) = (p(j), a(j), \lambda(j))$ 和最优值 $e_{best}(j) = E(p(j), a(j), \lambda(j))$; 否则不更新位置。

若 $p_{best}(j) < g_{best}(j)$, 更新全局最优位置 $(g_1(j), g_2(j), g_3(j)) = (p_{best}(j), a_{best}(j), \lambda_{best}(j))$ 和最优值 $g_{best}(j) = e_{best}(j)$; 否则不更新。

计算动态惯性权重值 $w = W_{\max} - (W_{\max} - W_{\min}) * n / T$ 并更新位置和速度。

(4) GA 求解资源分配和任务卸载策略优化问题

选择: 采用轮盘赌选择策略, 计算出 E 中数值的总和 $sum_E(n)$ 以及每一个个体的概率 $P(i) = 1 - E(i) / sum_E(n)$ 。

交叉: 随机产生概率 P_1 , 如果 $P_1 < P_c$, 分别随机生成两条染色体 $(p1, p2)$, $(a1, a2)$, $(\lambda1, \lambda2)$, 随机生成两个自然数 $r1$ 和 $r2$, $p1(r1:r2)$ 与 $p2(r1:r2)$ 交换; $a1(r1:r2)$ 与 $a2(r1:r2)$ 交换; $\lambda1(r1:r2)$ 与 $\lambda2(r1:r2)$ 交换。

变异: 随机产生概率 P_2 , if $P_2 < P_m$, 产生一个随机自然数 $r3$, 随机生成一条染色体 $(p3, a3, \lambda3)$, 对 $(p3(r3), a3(r3), \lambda3(r3))$ 进行变异为 (p_3, a_3, λ_3) 的值。

3 仿真与分析



本章通过仿真验证和分析所提方案和算法的性能。考虑 $500m \times 500m$ 的正方形区域, 移动设备和边缘节点随机分布在整块区域中, 其中三角形用于表示边缘节点, 圆形用于表示移动设备。仿真参数的设置主要参考文献[27], 表 1 给出了实验仿真中使用到的一些基本参数。


表 1 实验仿真参数

Table 1 Experimental simulation parameters


参数	符号表示	取值	参数	符号表示	取值
B	信道带宽/MHz	1	p_j^E	边缘节点的发送功率/w	3
α	路径损耗因子	4	p_{\max}	移动设备发送到边缘节点最大发射功率/w	2
ζ	瑞利衰落系数	1	T_0	SAA 算法的初始温度	100
σ_i^2	第 i 个移动设备的噪声	10^{-3}	T_{\min}	SA 算法的结束温度	90
	功率/W		r	SA 算法的温度下降速率	0.98
ρ_e	由芯片结构确定的开关电容/F	10^{-28}	m	AOA 算法的蚂蚁个数	20
$L_{j,i}$	任务的数据量/Mbits	[0.1,0.5]	ρ	AOA 算法的信息素挥发系数	0.8
f_e	边缘节点 CPU 的频率/GHz	1	P_0	ACA 算法的转移概率常数	0.2
R_j	第 j 个边缘节点与云服务器之间的传输速率/MB/s	100	N_p	PSO 算法的粒子个数	100
ρ_c	由芯片结构确定的开关电容/F	10^{-28}	c	PSO 算法的学习因子	1.5
f_c	云服务器 CPU 的频率/GHz	1	P_c	GA 算法的交叉概率	0.8
			P_m	GA 算法的变异概率	0.05
			NP	GA 算法的染色体个数	100

图 2 到 5 比较了采用 SAA、ACA、PSO 和 GA4 种算法来求解最优用户接入问题。边缘节点数量 J 均设置为 4、移动设备数量 I 分别设置为 4、6、8、10 的场景下的仿真结果。由图可以看出，4 种算法都可以求得较好的最优用户接入矩阵，移动设备选择哪一个边缘节点主要考虑距离因素。同时，可以发现有些移动设备会选择距离较远的边缘节点，这是因为如何选择还与任务大小和边缘节点的能量限制有关。

(a) $I = 4 \quad J = 4$ (b) $I = 6 \quad J = 4$




(c) $I = 8 \ J = 4$




(d) $I = 10 \ J = 4$

图 2 用户接入情况在不同移动设备数量下的对比(SAA)


Fig. 2 Comparison of user access under different number of mobile devices (SAA)




(a) $I = 4 \ J = 4$



(b) $I = 6 \ J = 4$




(c) $I = 8 \ J = 4$




(d) $I = 10 \ J = 4$

图 3 用户接入情况在不同移动设备数量下的对比(ACA)

Fig. 3 Comparison of user access under different number of mobile devices (ACA)



(a) $I = 4 \ J = 4$



(b) $I = 6 \ J = 4$

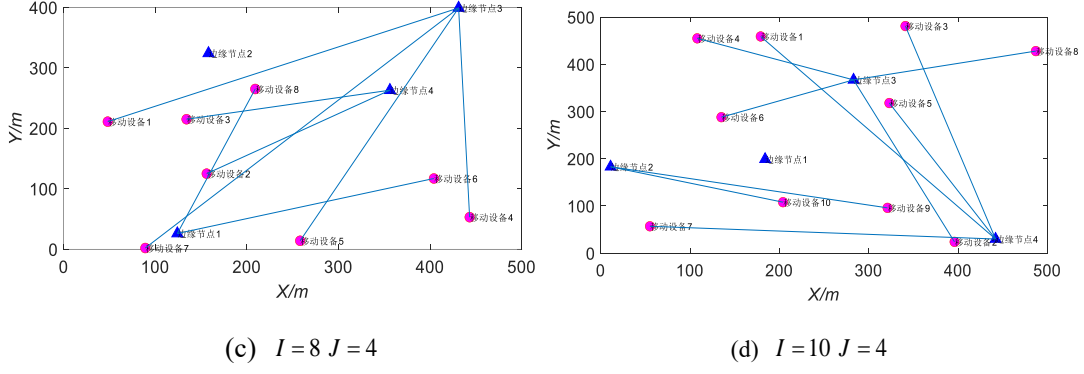


图 4 用户接入情况在不同移动设备数量下的对比(PSO)

Fig. 4 Comparison of user access under different number of mobile devices (PSO)

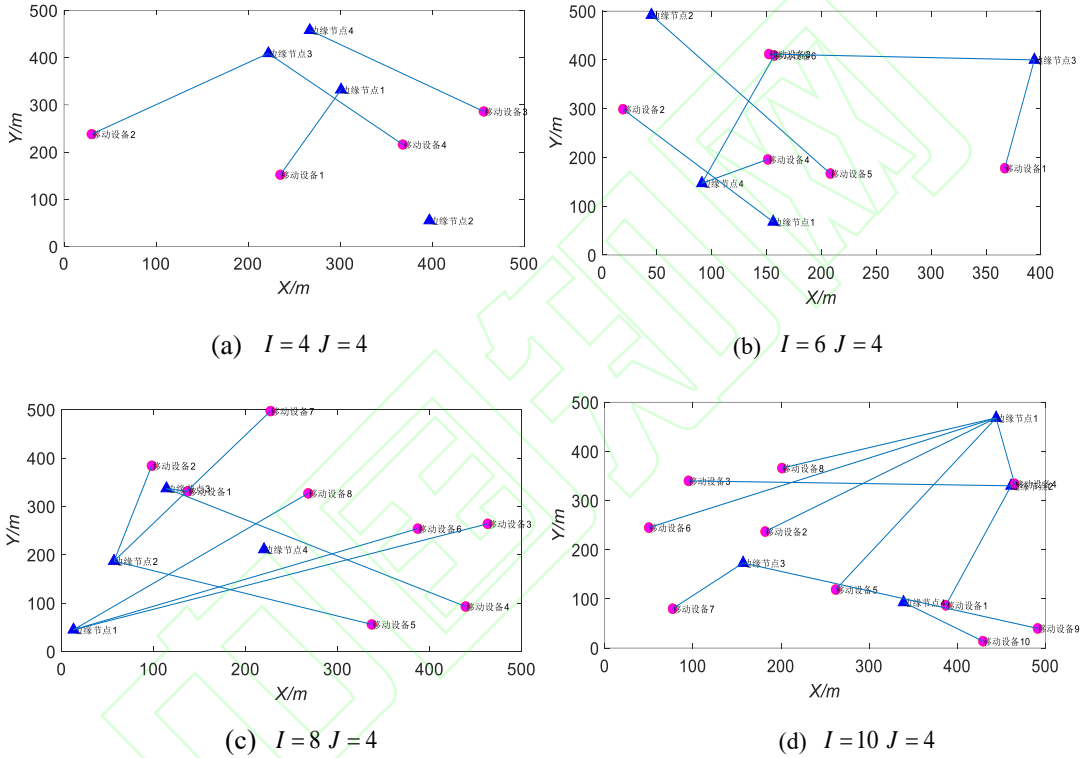


图 5 用户接入情况在不同移动设备数量下的对比(GA)

Fig. 5 Comparison of user access under different number of mobile devices (GA)

图 6 显示了在 10 台移动设备、5 个边缘节点的场景下，SAA、AOA、PSO 和 GA 四种不同算法的能耗收敛图。从图中可以看出，ACO 算法的收敛性最弱所得到结果的能耗性能较差；PSO 算法和 GA 算法虽然收敛性没有 SA 算法强，但是所得到结果的能耗性能较好。这是因为 PSO 算法和 GA 算法有着更强的随机性，有着更大概率得到更高的能耗性能。

图 7 比较了本文所提算法与任务卸载比例固定为 $\lambda=0.5$ 时，SAA、AOA、PSO 和 GA 四种算法卸载任务时能耗随迭代步数收敛的仿真结果。从图中可以看出本文所提算法随着迭代次数的增加所消耗的能耗比卸载比例估计 $\lambda=0.5$ 时低很多。这是因为任务卸载比例取值时不能智能化的分配卸载任务，并最大限度地降低能耗。由此可以说明采用智能优化算法能

够更大限度地降低能耗且效果明显。

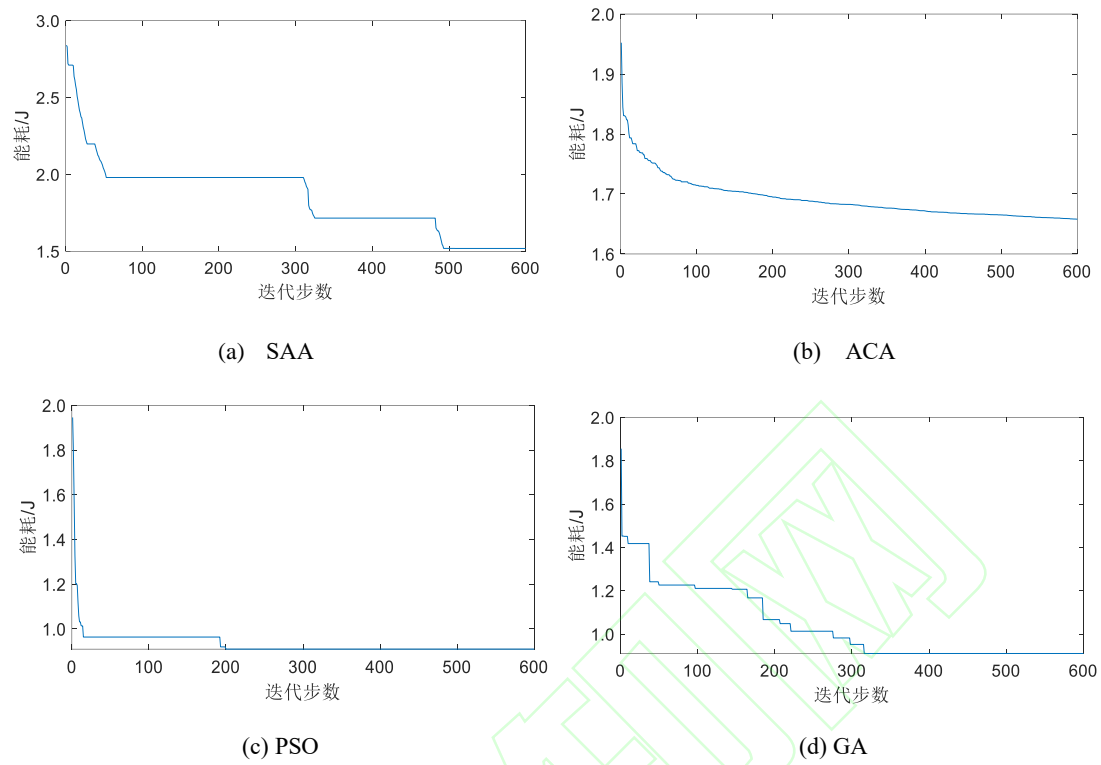


图 6 4 种算法的收敛曲线

Fig. 6 Convergence curves of the four algorithms

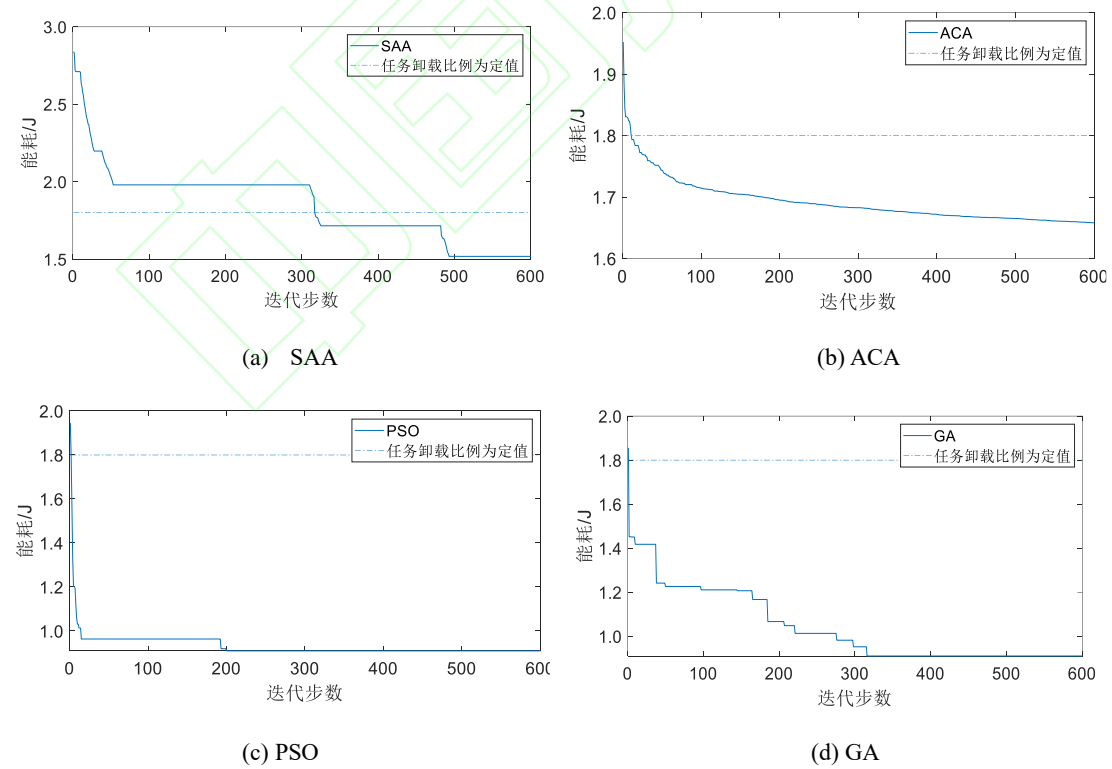


图 7 4 种算法与 λ 取定值时能耗比较

Fig. 7 Energy consumption comparison between the four algorithms and λ for a fixed value

图 8 展示了 SAA 算法在初始温度为 100、结束温度为 90、温度下降速率 r 分别取 0.92、

0.94、0.96、0.98 的情况下能耗的变化曲线。仿真实验可以看出，随着温度下降速率的增加，能耗收敛性更强，温度下降速率的增加意味着迭代次数的增加，有助于较快求得最优解。因此本文 SA 算法在温度下降速率取 0.98 时所得结果更小并且效果更好。

图 9 展示了 ACA 算法在蚂蚁个数为 20、信息素蒸发系数分别取 0.2、0.4、0.6、0.8 的情况下能耗的变化曲线。从仿真实验可以看出，随着信息素蒸发系数的减少，能耗收敛性更强。这是因为随着信息素蒸发系数的减少，算法的收敛性有所增强。由此可以说明本文 ACA 算法在信息素蒸发系数取 0.2 时所得结果更小并且效果更好。

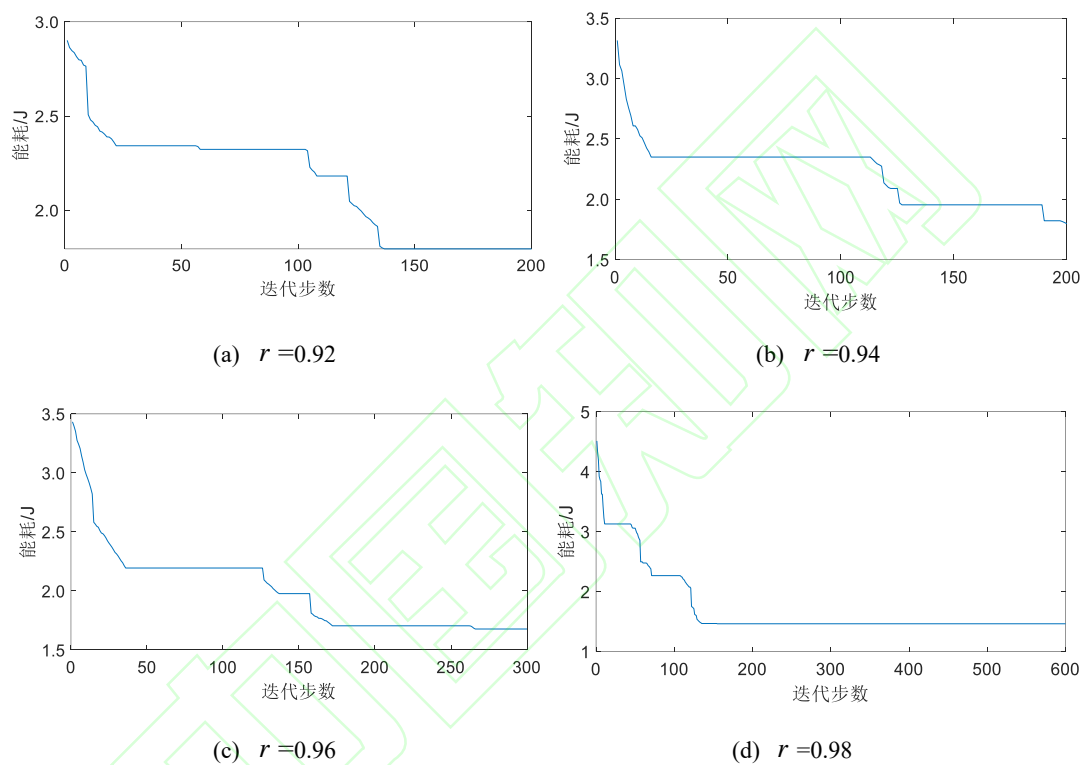



图 8 不同温度下降速率的 SAA 能耗收敛曲线

Fig. 8 SAA energy consumption convergence curves of different temperature drop rates






图 9 不同信息素蒸发系数的 ACA 能耗收敛曲线

Fig. 9 ACA energy consumption convergence curve of with different pheromone evaporation coefficients

图 10 展示了 PSO 算法在粒子个数为 100、学习因子分别为 0.9、1、1.1、1.2 的情况下能耗的变化曲线。从仿真实验可以看出，随着学习因子的减少，曲线收敛性更强。这是因为随着学习因子的减少，PSO 算法更加注重局部搜索，有利于找到更优的局部最优解。这说明在本文中 PSO 算法的学习因子取 0.9 的效果最好且能耗收敛性更强。

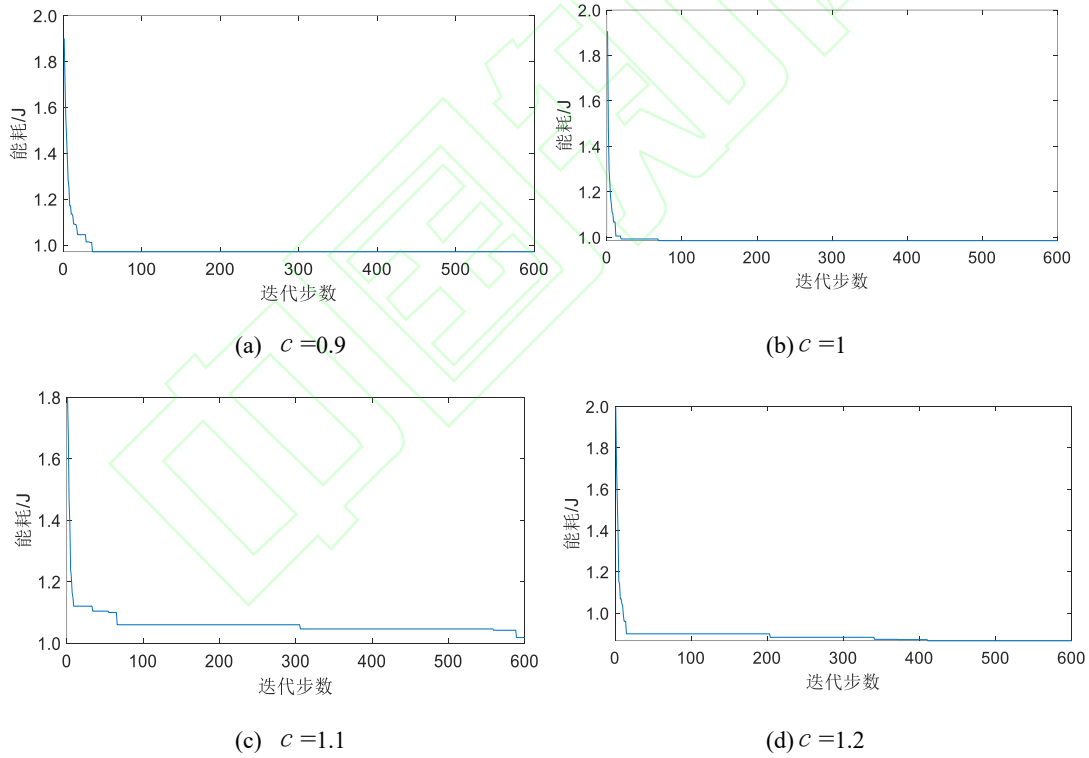


图 10 不同学习因子的 PSO 能耗收敛曲线

Fig. 10 PSO energy consumption convergence curve of different learning factors

图 11 给出了 GA 算法在变异概率为 0.05、交叉概率分别取 0.6、0.7、0.8、0.9 的场景下能耗与迭代次数的仿真结果。从仿真实验可以看出，不同交叉概率的能耗曲线收敛性较好。

图 12 给出了 GA 算法在交叉概率为 0.8、变异概率分别取 0.001、0.01、0.05、0.1 的场景下能耗与迭代次数的仿真曲线。从仿真实验可以看出，随着变异概率的增加，能耗曲线收

敛性更好。

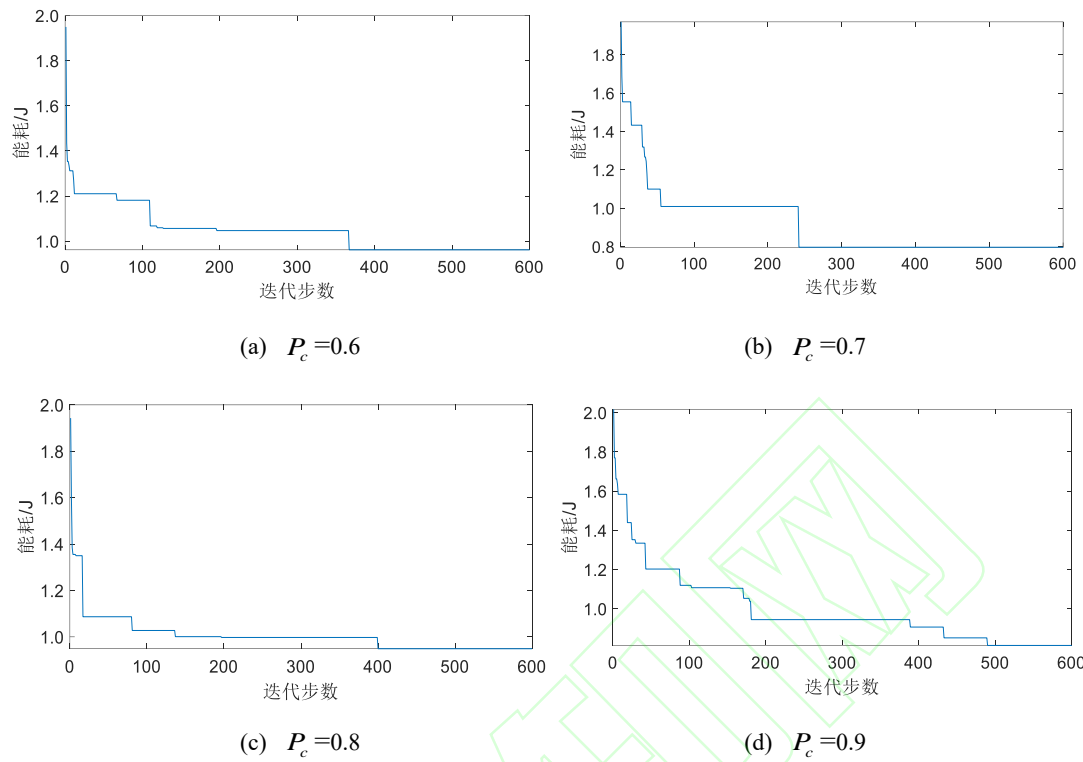


图 11 GA 中不同交叉概率的能耗收敛曲线

Fig. 11 Energy consumption convergence curves with different crossover probabilities in GA

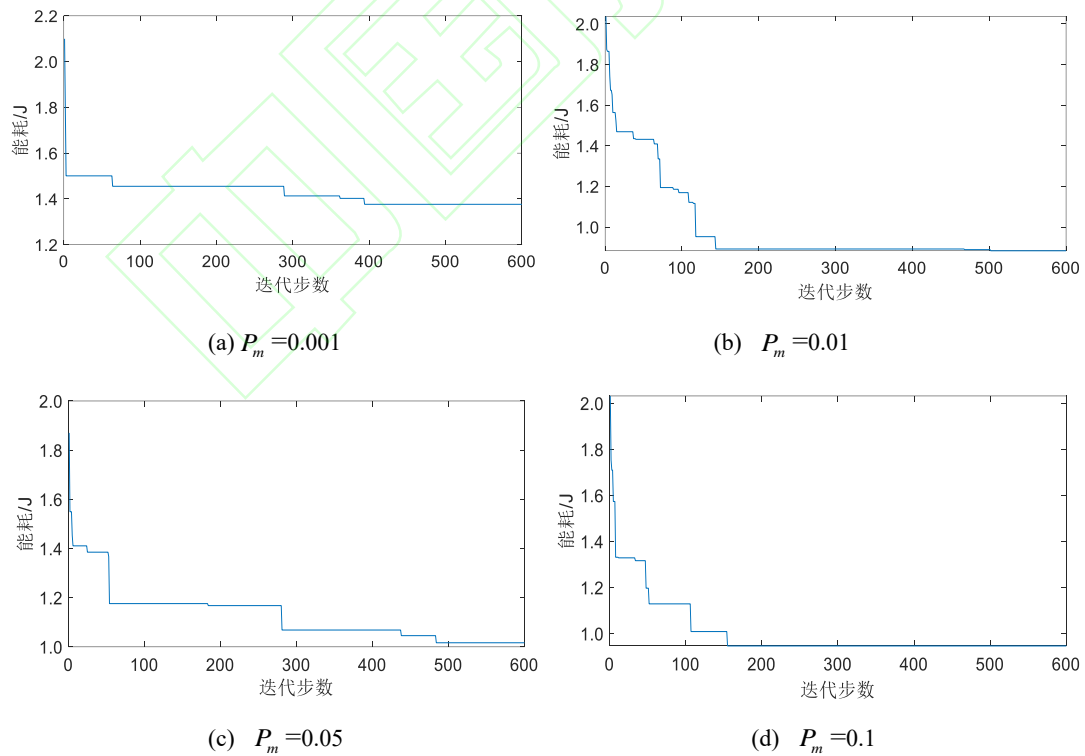


图 12 GA 中不同变异概率的能耗收敛曲线

Fig. 12 Energy consumption convergence curves of GA with different mutation probabilities

SAA 的初始解个数、ACA 的蚂蚁个数、PSO 的粒子数量和 GA 的染色体个数统称为样

本容量 N 。图 13 给出了 N 分别取 500、1000、1500、2000 的场景下能耗与迭代次数的仿真曲线。从仿真实验可以看出，随着染色体个数的增加，PSO 算法一直保持着最好的效果。




图 13 4 种算法不同样本容量的能耗收敛曲线

Fig. 13 Energy consumption convergence curves of the four algorithms with different numbers of sample size

4 结束语

本文研究探讨了在云边协同移动边缘计算网络中能耗最小化任务卸载策略技术的重要性。首先，我们构建了一个旨在最小化系统总能耗的联合边缘节点和云服务器的任务卸载问题。该问题被分解为用户接入和能耗最小化两个子问题，并利用 SAA、ACA、PSO 和 GA 进行求解。仿真结果表明，所采用的方法在一定程度上成功降低了能耗，并且所提出的算法展现出了良好的收敛性。相较于固定参数的方案，本文所研究的方案能有效提高系统的资源利用率，并降低系统的整体能耗，有较好的实用性。在处理复杂、大规模、高动态的跨异构接入网络任务卸载问题时，传统任务卸载方法面临无法适应动态环境的问题。因此未来的研究将利用机器学习算法，开发智能化的动态任务卸载策略，通过实时分析网络状况与边缘节点的计算能力，优化任务分配，动态调整卸载决策，同时实现能耗和时延最小化，以提高边缘计算网络的整体性能。

参考文献

[1] GAO J , CHANG R , YANG Z, et al. A Task Offloading Algorithm for Cloud-edge

- Collaborative System Based on Lyapunov Optimization[J]. Cluster Computing,2023:337-348.
- [2] XU J , LIN J , LI Y , et al. MultiFed: A Fast Converging Federated Learning Framework for Services QoS Prediction Via Cloud-edge Collaboration Mechanism[J]. Knowledge-Based Systems, 2023:268.
- [3] 代美玲,刘周斌,郭少勇等.基于终端能耗和系统时延最小化的边缘计算卸载及资源分配机制[J].电子与信息学报,2019,41(11):2684-2690.
- [4] REN J , YU G , HE Y ,et al.Collaborative Cloud and Edge Computing for Latency Minimization[J].IEEE Transactions on Vehicular Technology,019:1-1.
- [5] KAI C , ZHOU H , YI Y ,et al. Collaborative Cloud-Edge-End Task Offloading in Mobile-Edge Computing Networks With Limited Communication Capability[J].IEEE Transactions on Cognitive Communications and Networking, 2021, 7(2):624-634.
- [6] YAN L, CHEN H, TU Y and ZHOU X, A Task Offloading Algorithm With Cloud Edge Jointly Load Balance Optimization Based on Deep Reinforcement Learning for Unmanned Surface Vehicles, IEEE Access, 2022:16566-16576.
- [7] 唐帅,庞凝,李光毅, 等.云边协同区域能源互补决策模型与算法[J].全球能源互联网,2022,5(5):480-487.
- [8] CAO J ,MA Z ,XIE J , et al. Towards Tenant Demand-aware Bandwidth Allocation Strategy in Cloud Datacenter[J]. Future Generation Computer Systems,2020,105 : 904-915.
- [9] ABBASI M, MOHAMMADI E, KHOSRAVI M. Intelligent Workload Allocation in IoT-Fog-Cloud Architecture towards Mobile Edge Computing[J]. Computer Communications, 2021, 169(3): 71–80.
- [10] LI Wen Zao, WANG Fang Xin, PAN Yu Wen, et al. Computing Cost Optimization for Multi-BS in MEC by Offloading[J]. Mobile Networks and Applications, 2020, 25(4): 1628–1641.
- [11] ZHU Zheng Ying, QIAN Li Ping, SHEN Jia Fang, et al. Joint Optimisation of UAV Grouping and Energy Consumption in MEC Enabled UAV Communication Networks[J]. IET Communications, 2020, 14(16):2723–2730.
- [12] XIE Ren Chao, LI Zi Shu, WU Jun, et al. Energy-efficient Joint Caching and Transcoding for HTTP Adaptive Streaming in 5G Networks with Mobile Edge Computing[J].China Communications, 2019, 16(7):229–244.
- [13] FENG Si Ling, CHEN Yinjie, ZHAI Qianhao, et al. Optimizing Computation Offloading

Strategy in Mobile Edge Computing Based on Swarm Intelligence Algorithms[J]. EURASIP Journal on Advances in Signal Processing, 2021, 2021(1): 1–15.

- [14] LIU Zhi Zhong, SHENG Quan, XU Xufei, et al. Context-aware and Adaptive QoS Prediction for Mobile Edge Computing Services[J]. IEEE Transactions on Services Computing, 2019, 30(9): 125–139.
- [15] LIANG Liang, XIAO Jintao, REN Zhi, et al. Particle Swarm Based Service Migration Scheme In The Edge Computing Environment[J]. IEEE Access, 2020, 8: 45596–45606.
- [16] MA Shu Yue, SONG Shu Dian, ZHAO Jing Mei, et al. Joint Network Selection and Service Placement Based on Particle Swarm Optimization for Multi-access Edge Computing[J]. IEEE Access, 2020, 8:160871–160881.
- [17] YOU Qian, TANG Bing. Efficient Task Offloading Using Particle Swarm Optimization Algorithm in Edge Computing for Industrial Internet of Things[J]. Journal of Cloud Computing, 2021, 10(1): 1–11.
- [18] 王涛,喻韬.一种基于遗传模拟退火算法的通信卫星资源规划方法[J]. 无线电工程,2021,51(8):767-772.
- [19] FANG T , TIAN H , ZHANG X ,et al.Context-aware Caching Distribution and UAV Deployment: A Game-theoretic Approach[J].Applied Sciences,2018,8(10):1959.
- [20] JI J , ZHU K , NIYATO D ,et al.Joint Cache Placement, Flight Trajectory and Transmission Power Optimization for Multi-UAV Assisted Wireless Networks[J].IEEE Transactions on Wireless Communications, 2020, 19(8):5389-5403.
- [21] JIANG B , YANG J , XU H ,et al.Multimedia Data Throughput Maximization in Internet-of-Things System Based on Optimization of Cache-Enabled UAV[J].IEEE Internet of Things Journal, 2019,6(2):3525-3532.
- [22] ZHANG T , WANG Y , LIU Y ,et al.Cache-enabling UAV Communications: Network Deployment and Resource Allocation[J].IEEE Transactions on Wireless Communications, 2020,19(11):7470-7483.
- [23] 刘毅,唐秋华,何明.基于增强模拟退火算法的动车所调车作业计划多目标优化方法[J].铁道运输与经济,2024,46(2):10-19.
- [24] 周振,耿晨晨,崔若庚,等.基于改进融合蚁群算法的 AGV 路径规划[J].计算机仿真,2024,41(4):441-445.

- [25] 左国玉,李宓,郑榜贵.基于改进自适应多目标粒子群算法的机械臂最优轨迹规划方法[J].实验技术与管理,2024,41(3):184-191.
- [26] 黄昱舟,胡庆玉,熊华乔.基于改进遗传算法的无人水下航行器路径规划[J].数字海洋与水下攻防,2024,7(2):215-224.
- [27] 吴启晖,吴伟.无人机辅助边缘计算的能效效率最大化算法设计[J].通信学报,2020,41(10):15-24.

作者简介

朱仪 男,(1999—),硕士研究生。主要研究方向:边缘计算网络资源优化。

(*通信作者)江雪 女,(1982—),博士研究生,讲师。主要研究方向:干扰对齐、拓扑干扰管理、边缘计算网络资源优化。